

RAG Knowledge Nexus

智能文档问答助手

需求规格说明书 & 技术设计文档

版本：v2.0（轻量版架构）

向量存储方案：Qdrant

日期：2026-06-11 | 状态：已发布

四、向量存储方案选型（核心设计决策）

4.1 三种方案对比

■	Milvus	Qdrant■■■■	Apache Lucene
■■■■■	■■■■■+etcd+MinIO	■■■■■■■■■■	■■■ JVM■■■■■
■■■■■■■	Docker Compose>=3■■■	■■■■■■■■	■■■■■■■Maven■■■
■■■■■	2GB+	~256MB	■■■■■
■■■■■	HNSW/IVF/DiskANN	HNSW	HNSW■Lucene9.0+■
■■■■■	■ gRPC	REST + gRPC	■■■ Java API
■■■■■■■	MinIO/Pulsar	■■■■■	■■■■■■■■
■■■■■	■■■■■■■■■	Payload■■■■■■■	■■■■■BooleanQuery
■■■■■	Attu Dashboard	■■■ Web Dashboard	■
■■■■■	■■■■■■■■■	■■■/■■■■■	■■■■■■■■■

4.2 为什么选 Qdrant

在三款方案中，Qdrant 是个人 RAG 项目的最佳平衡点，核心理由如下：

- 专业性：真正的向量数据库，Collection+Payload+Dashboard，简历比 Lucene 专业
- 轻量：单二进制一条命令启动，运维成本≈Lucene
- Payload 过滤：原生按 kbId/docId 过滤，多租户权限隔离
- Rust 高性能：HNSW 单机百万级向量
- REST API：与项目 OkHttp 完全一致，零额外 SDK
- 面试叙事干净：比 Lucene 专业，比 Milvus 务实